

ПИЛОТНАЯ ПОСТКОРРЕКЦИЯ АРАБОГРАФИЧНОГО ТЮРКСКОГО ТЕКСТА


не OCR с картинки, а проверяемый слой после распознавания

post-correction

ByT5-small

real-OCR sanity



Радмир • НИУ ВШЭ • 2026



Ключевая рамка: исправляем уже полученный шумный OCR/OCR-like текст.

Где именно проблема

между распознаванием и анализом текст ещё надо исправить



Почему это важно

Ошибки OCR ломают поиск, индексацию, извлечение сущностей и последующий историко-лингвистический анализ.

Фокус работы: не “распознать страницу”, а проверить, можно ли улучшать уже полученный OCR-текст.

Почему задача неприятная

арабская графика + историческая орфография + мало данных

Арабская графика

позиционные формы, точки, похожие начертания

Историческая орфография

вариативность нельзя грубо нормализовать

Мало данных

нет большого готового benchmark именно для этой постановки

Метрики неполны

CER/WER нужны, но не заменяют ручную проверку

ایکینچی قسم (دنیہ پر) نہرینک ساحل یسارندہ واقعہ درکہ بوقسم
(پولتاوا)، (چہر نیہوف) و (خارقوف) ایالتی احتوا ایدر .
اوچینچی قسم قرہ دکز حوالی ساحلہ سندہ بولنان جیم اووہ لردن
عبارتدرکہ بوندہ (قاہرینوسلاو)، (خرسون) و (طورید)
ایالتی موجوددر .
بوتون بواراضیدہ ساکن اعالیئک مقدار مجموعی۔ (خولم) ایاتی داخلی
حساب ایدلماک شرطیہ ۱۸۹۷ء وقوع بولان تحریر نفوسہ نظرآ
۲۳،۴۳۰،۴۰۷ بالغ اولقده درکہ ۱۷،۰۰۵،۶۸۸ ی اوقراینالیدر.
شو حسابہ کورہ اوقراینالیر ۱۸۹۷ء اوقرایناراضی اصلہ سندہ کی
سکھنک یوزدہ یتش ایکینی تشکیل ایتمکدہ ایدی. بوقطعہ اھالیسی
۱۹۱۰ء تقریباً ۲۲،۰۰۰،۰۰۰ سی اوقراینالی اولق اوزرہ
۳۰،۳۶۰،۰۰۰ رادہ سندہ ایدی.
بوندن ماعددا اوقراینالیر زبردہ تعداد ایدہ جکمز ایالتدرہ
وقطعہ لردہ نفوسک اکثریتی یامہم بر قسمی تشکیل ایتمکدہ درلر :
(قورسق)، (وورونہز)، (دون)، (استاوروپول)، (قوبان)،
(تہرہک)، (بشارابا) و ساڑہ . (وولغا) نہری اوزرندہ کائن
(سامارا) ایالتیہ قفقاسیادہ اوقراینالی جماعتاری وادر . سیریادہ
اوقراینالیر سائر اقوامہ نسبہ اکثریتی جائز بولنورلر. ۱۸۹۷ تحریر
نفوس نتیجہ سندہ بوتون روسیہدہ یکرمی یدی میلیون اوقراینالی مقیم
اولدینی آکلاشایدی. شیمدی ایسہ اوقراینالیرک مقدار مجموعی اوتوز
میلون قدردر .
اوقرایناراضی اصلہ سندک تقسیمات ادارہ سیلہ بواراضیدہ ہانکی
قومدن نہ مقداردہ سکھہ موجود اولدینی آئی بہ درج ایتمکدہ کمز
... ضد اس ...

Что нельзя делать

“Почистить всё правилами” — можно стереть исторически значимые варианты.





Что делаем

Узкий воспроизводимый pilot:
noisy/OCR text → clean text.

Стратегия: честный pilot study вместо обещания “полной OCR-системы”.

Что построено в проекте

контролируемый pipeline: данные → шум/OCR → модель → метрики



Инженерная деталь

Split сделан по исходным clean lines: варианты одной строки не попадают в разные split-ы.

Отдельно добавлен sanity check на real OCR: page image → Tesseract → noisy OCR text → ByT5.

Методология: честное сравнение

не одна модель в вакууме, а baseline → model → error analysis



Identity baseline

ничего не исправляет: нижняя граница качества

Rule-based normalizer

проверка: помогают ли простые правила

Char-confusion baseline

простая модель ошибок по train split

ByT5-small 512

byte-level seq2seq для noisy/OCR → clean

Метрики

CER — character edits

WER — word edits

NoSpaceCER — без влияния пробелов

ExactMatch — строгая строка

line behavior — improved / unchanged / worse

Зачем NoSpaceCER?

WER может заметно улучшаться из-за пробелов и границ слов. NoSpaceCER показывает, есть ли посимвольный эффект без whitespace.

Метрики дают сигнал, но не заменяют ручную проверку исторического текста.

Synthetic benchmark results

ByT5-small 512 помогает; простые rules вредят

CER

0.086 → 0.080

identity → ByT5

WER

0.519 → 0.369

identity → ByT5

Rule-based

хуже

CER 0.152 / WER 0.684

Главный synthetic result

ByT5-small — лучший среди рассмотренных методов, но это controlled benchmark.

CER


Identity



Rule-based



ByT5



WER

Identity



Rule-based



ByT5



Не “прорыв”: полезный пилотный сигнал, WER лучше заметно, CER — умеренно.

Одна средняя метрика не всё объясняет

line-level behavior показывает пользу и риск модели

CER improved

682 / 800

lines

CER unchanged

60 / 800

lines

CER worsened

58 / 800

lines

Whitespace sanity

Raw WER improvement: 0.159

No-space CER improvement: 0.010

Интерпретация

WER gain частично связан с пробелами, но synthetic effect не только whitespace artifact.

85.3%

Полезность ≠ безопасность: model outputs нужно проверять на худших случаях.

Качественные примеры

3 кейса: помогла / почти не изменила / ухудшила

ایدلامک شرطیله – ۱۸۹۷ ده وقوع بولان تحریر نفوسه نظراً
۲۳,۴۳۰ یه بالغ اولمقدمه در که ۱۷,۰۰۵,۶۸۸ ی اوقراینالیدر.
ما به کوره اوقراینالیر ۱۸۹۷ ده اوقرایناراضی* اصلیه سنده کی
ک یوزده یتش ایکسینی تشکیل ایتکده ایدی. بوقطعه اهالیسی
ده تقریباً ۲۲,۰۰۰,۰۰۰ سی اوقراینالی اولق اوزره

фрагмент реальной страницы

1) Improved

OCR: “أبالتلرنی احتوا ایدر ... (بولتاوا)”

ByT5: “أبالتلرنی احتوا ایدر ... (بولتاوا)”

Clean: “و(خارقوف) أیالتلرینی احتوا ایدر (چهرنیهوف)، (بولتاوا)”

2) Unchanged

Модель оставляет строку почти без изменений. Это безопасно, но не исправляет реальные character-level ошибки.

3) Worsened

Локальная правка может ухудшить CER: модель меняет похожие фрагменты, но не восстанавливает ключевые буквы.

Именно поэтому в работе есть error analysis, а не только одна итоговая таблица.

проверка переноса synthetic-trained ByT5 на Tesseract output

CER 0.4508

CER 0.4361

40 / 90

33 / 90

17 / 90

Transfer есть: ВуТ5 улучшает больше real-OCR строк, чем ухудшает.

NoSpaceCER почти не меняется: real character-level correction пока ещё слабая.

[illegible]

Arabic-script Turkic OCR post-correction • course paper defense

Финал для защиты

reproducible pilot benchmark, но ещё не готовая OCR-система

Что уже есть

synthetic benchmark; baselines; ByT5 лучше identity по CER/WER; robustness/fallback; real-OCR sanity check.

Что остаётся future work

verified real benchmark; line crops/PAGE XML/hOCR; несколько OCR engines; real-error-aware synthetic noise.

Главная фраза

“Это не OCR-система с картинки, а проверенный слой post-correction и основа для будущего OCR/HTR benchmark.”



Вклад работы: воспроизводимый pilot benchmark, baselines, real-OCR sanity и честные ограничения.