

OCR POST-CORRECTION ДЛЯ ИСТОРИЧЕСКИХ ТЮРКСКИХ ТЕКСТОВ

в арабской графике

Главная мысль

**Синтетика учит модель исправлять
«похожий» шум,
но настоящий OCR ломается иначе.**

post-correction

ByT5-small

real-OCR benchmark

Радмир Исламов · НИУ ВШЭ · 2026



Постановка: не «просто OCR», а post-correction

Вход — ошибочный OCR-текст; выход — текст ближе к проверенной транскрипции




Фокус работы

Не обучаем OCR с нуля. Проверяем, можно ли улучшать уже полученный OCR/OCR-like текст.

Домен

Исторические тюркские тексты в арабо-персидской графике; текущий real-OCR источник — османско-турецкий печатный текст.



Почему задача сложная

Арабская графика + историческая орфография + малые открытые корпуса

Арабская графика

позиционные формы, точки, похожие начертания

Историческая орфография

вариативность
нельзя грубо нормализовать

Мало данных

нет большого готового benchmark именно для этой постановки

Метрики неполны

CER/WER нужны, но не заменяют ручную проверку

Что нельзя делать

«Почистить всё правилами» — можно стереть исторически значимые варианты.

Что делаем

Узкий воспроизводимый pilot: noisy/OCR text → clean text.

Главный риск

модель выглядит успешной на synthetic benchmark, но не переносится на настоящий OCR

Synthetic benchmark: контролируемый пилот

Модель учится на парах noisy → clean

Инженерная деталь

Split сделан по clean lines:
варианты одной строки не
попадают в разные split-ы.

clean
corpus

synthetic
noise

noisy
text

ByT5 /
baselines

metrics
+ errors

corpus

400

clean unique lines

split

320/40/40

train / val / test

pairs

8000

noisy-clean pairs

model

ByT5-512

best model

Synthetic results: модель работает, но не идеально

На синтетике ByT5 снижает WER заметнее, чем CER

Identity CER

0.086

ByT5 CER

0.080

Identity WER

0.519

ByT5 WER

0.369


Rule-based

хуже

Интерпретация

CER улучшается умеренно. WER падает сильнее, потому что synthetic noise включает пробелы.

CER ↓



Чем ниже, тем лучше

WER ↓



Чем ниже, тем лучше

Real-OCR benchmark: что добавили

Османско-турецкий источник как доступный Arabic-script Turkic test case

pages total

72

rendered
pages

eval pages

68

filtered subset

clean chars

90k

reference text

OCR chars

82k

Tesseract
output

Что это НЕ есть

Это не старотатарский и не старобашкирский датасет. Источник используется как связанный Arabic-script Turkic test case.

Что хранится в репозитории

Скрипты и агрегированные summary-таблицы. PDF, page images, OCR outputs, gold text и predictions остаются локально.

۵۷

ایکینچی قىم (دنيه پەر) نهرينك ساحل يسانده واقعدركه بوقىم
(پولتاوا)، (چهرينهوف) و (خارقوف) ايتلرني احتوا ايدر .
اوچينچی قىم قره دكز حوالى* ساحليه سنده بولان جسيم اووه لردن
عارتدركه بونده (قاهرينوسلاو)، (خرسون) و (طوريد)
ايتلرني موجوددر .

بوتون بواراضيده ساكن اهانك مقدار مجموعىـ(خولم) اياتي داخلي
حساب ايدلامك شرطيه ـ ۱۸۹۷ده وقوع بولان تحرير نفوسه نظراً
۲۳،۴۳۰،۴۰۷ يبالغ اولقده دركه ۱۷،۰۰۵،۶۸۸ ي اوقرايناليدر.
شو حساب كورده اوقرايناليلر ۱۸۹۷ده اوقراينا اراضى* اصليه سنده كي
سكنه نك يوزده ينش ايكيى تشكيل اينكده ايدى. بوقطعه اهاليى
۱۹۱۰ ده تقريباً ۲۲،۰۰۰،۰۰۰ سى اوقراينالى اولق اوزره
۳۰،۳۶۰،۰۰۰ راده سنده ايدى.

بوندن ماعدا اوقرايناليلر زيرده تعداد ايدم جكمز ايتلرده
وقطعه لرده نفوسك اكثرينى يامهم بر قسمنى تشكيل اينكده درلر :
(قورسق)، (وورونه ز)، (دون)، (استاوروپول)، (قوبان)،
(تهرهك)، (يسارابيا) و سائر . (وولغا) نهرى اوزرنده كائن
(سامارا) ايتليه قفقاسياده اوقراينالى جماعتارى واردر . سيرياده
اوقرايناليلر سائر اقوامه نسبه* اكثرينى حائر بولنورلر. ۱۸۹۷ تحرير
نفوس نتيجه سنده بوتون روسيه ده بكمى يدى ميلون اوقراينالى مقىم
اولدينى آكلاشليدى. شيمدى ايسه اوقرايناليلرك مقدار مجموعى اوتوز
ميلون قدردر.

اوقراينا اراضى* اصليه سنك تقسيمات اداريه سيلاه بواراضيده هانكى
قومدن نه مقدارده سكنه موجود اولدينى آنى به درج ايتسدكمز
حدولده موضعا* كوستلنكده در :

Real transfer: CER ухудшается

Synthetic-trained ByT5 не переносится надёжно на full-page OCR

Mean CER ↓



Чем ниже, тем лучше

ByT5: 0.3539 → 0.4564

CER растёт, значит символный слой ухудшается.

Strict guard: 0.3828

безопаснее, но всё ещё хуже raw OCR.

Character-level ошибка критична

Для арабского OCR CER важнее красивой word-level картинки.

Real transfer: WER слегка лучше, но это не спасает

Word-level улучшение не равно надёжной OCR-коррекции

Mean WER ↓



Чем ниже, тем лучше

Интерпретация

WER падает, но NoSpaceCER и CER растут. Значит, модель может править пробелы, но портить символы.

ByT5 improved

6

pages by CER

ByT5 worse

62

pages by CER

Вывод

Если символы портятся, модель нельзя считать надёжной OCR-посткоррекцией даже при более красивом WER.

Почему перенос провалился

Synthetic noise и real OCR noise имеют разную природу

Synthetic noise

text-level искажения: замены, удаления, пробелы

Real OCR noise

scan / layout / segmentation / font errors

Длина контекста

модель обучалась на строках, real benchmark сейчас page-level

OCR engine

Tesseract Arabic model не специализирован под османско-турецкую орфографию

real OCR
outputs

reference
chunks

page-level
split

domain
adaptation

Следующий обязательный шаг

real-domain adaptation на выровненных OCR/reference чанках с page-level split без утечки.

Итог

Работа честно закрывает synthetic benchmark и real-OCR sanity check

Что уже есть

- воспроизводимый pipeline для Arabic-script Turkic OCR post-correction
- synthetic benchmark и baseline-методы
- ByT5-small 512 лучший на synthetic benchmark
- page-level real-OCR sanity check
- честно зафиксированный synthetic-to-real gap

Главная фраза

«Это не готовая OCR-система, а хороший пилотный research pipeline с честным ограничением».

