

OCR post-correction

для исторических тюркских текстов в арабской графике

Курсовая работа · HSE · обновлённая версия с real-OCR benchmark

**Главная мысль: синтетика учит модель исправлять
“похожий” шум, но настоящий OCR ломается иначе.**

Радмир Исламов

Постановка: не “просто OCR”, а post-correction

Вход — ошибочный OCR-текст; выход — текст ближе к проверенной транскрипции

image → OCR → noisy text → post-correction → corrected text

Работа фокусируется на текстовой посткоррекции, а не на обучении OCR с нуля.

Целевой класс: исторические тюркские тексты в арабо-персидской графике.

Старотатарские и старобашкирские материалы — мотивация и будущий целевой домен.

Текущий доступный real-OCR источник: османско-турецкая печатная книга.

2

уровни эксперимента

yes

synthetic + real

Почему задача сложная

Арабская графика + историческая орфография + малые открытые корпуса

Для многих источников есть сканы, но нет постраничного gold text.

Синтетический шум не воспроизводит layout, качество скана, шрифт и ошибки сегментации.

Для арабографичных текстов CER важнее красивого word-level результата.

Даже если WER падает, модель может портить буквы и историческую орфографию.

Главный риск

**модель выглядит
успешной на
synthetic benchmark,
но не переносится
на настоящий OCR**

Synthetic benchmark: контролируемый пилот

Модель учится на парах noisy → clean

400

clean unique lines

320/40/40

train/val/test lines

8000

noisy-clean pairs

ByT5-512

best model

Сравнивались identity baseline, rule-based normalizer, train-derived confusion baseline и ByT5-small.

Разбиение сделано по clean lines, чтобы варианты одной строки не попадали одновременно в train и test.

Synthetic benchmark нужен как controlled environment, а не как доказательство готовности к архивным сканам.

Synthetic results: модель работает, но не идеально

На синтетике ByT5 снижает WER заметнее, чем CER

Identity CER 0.086

ByT5 CER 0.08

Identity WER 0.519

ByT5 WER 0.369

Интерпретация

CER улучшается умеренно.
WER падает сильнее, потому что synthetic noise включает пробелы и границы слов. ExactMatch остаётся низким: задача не сводится к полному восстановлению строки.
Вывод: подход перспективен в synthetic-среде, но требует проверки на real OCR.

Real-OCR benchmark: что добавили

Османско-турецкий источник как доступный Arabic-script Turkic test case

72

pages total

68

eval pages

90k

clean chars

82k

OCR chars

Важно: это не старотатарский и не старобашкирский датасет.

Источник используется как связанный тюркский текст в арабской графике.
PDF, page images, OCR outputs, gold text и predictions остаются локально.
В репозитории сохранены только скрипты и агрегированные summary-таблицы.

Real transfer: CER ухудшается

Synthetic-trained ByT5 не переносится надёжно на full-page OCR

Mean CER

Raw Tesseract



0.354

ByT5 chunked



0.456

Strict guarded



0.383

Чем ниже, тем лучше. По CER raw Tesseract остаётся лучшим.

ByT5: 0.3539 → 0.4564
Strict guard: 0.3828, безопаснее, но хуже raw OCR
Для арабского OCR character-level ошибка критична

Real transfer: WER слегка лучше, но это не спасает

Word-level улучшение не равно надёжной OCR-коррекции

Mean WER



WER падает, но NoSpaceCER и CER растут. Значит, модель может править пробелы, но портить символы.



Почему перенос провалился

Synthetic noise и real OCR noise имеют разную природу

Synthetic noise — text-level искажения; real OCR — ещё и scan/layout/segmentation/font errors.

Модель обучалась на коротких строках, а real benchmark сейчас page-level.

Tesseract Arabic model не специализирован под османско-турецкую орфографию.

Без aligned real OCR/reference chunks модель не видит настоящую структуру ошибок.

**Следующий
обязательный шаг**

**real-domain adaptation
на выровненных
OCR/reference чанках с
page-level split без
утечки**

Итог

Работа теперь честно закрывает synthetic benchmark и real-OCR sanity check

Собран воспроизводимый pipeline для Arabic-script Turkic OCR post-correction.

На synthetic benchmark ByT5-small 512 даёт лучший результат среди baseline-подходов.

На real page-level Ottoman Turkish OCR synthetic-trained ByT5 не превосходит raw Tesseract по CER.

Основной вывод: для практического применения нужна real-domain adaptation, а не только synthetic noise.

Не “готовая OCR-система”, а хороший пилотный research pipeline с честным ограничением.